

SOMMARIO

Classificazione di Immagini attraverso BoW.....	2
Presentazione problema.....	2
Pipeline adottata	2
Creazione del vocabolario visuale su AID	2
Classificazione.....	3
Scelte progettuali.....	3
Normalizzazione L-2 degli istogrammi BoW	4
Scelta dei classificatori Shallow.....	4
Iperparametri	4
Dimensionamento del vocabolario.....	4
Bilanciamento delle classi in cross-validation	4
Risultati ottenuti	5
Modello Vincente	5
Matrice di confusione del modello vincente	6
Problemi riscontrati	7
Possibili Miglioramenti	7
Nessuna informazione spaziale	8
Hard assignment	8
Bibliografia.....	8
Testi e Risorse Utilizzate.....	8

CLASSIFICAZIONE DI IMMAGINI ATTRAVERSO BOW

Assignment 2 del corso di Visione Artificiale, Ingegneria informatica - 2035 - LM-32

Studente: *Angelo Gulotta*, matricola 0830813

PRESENTAZIONE PROBLEMA

Dato un dataset di immagini aeree RGB, bisogna sviluppare un sistema completo per assegnare ogni immagine a una delle **21 classi** usando l'approccio classico BoW (Bag of Visual Words). Per assignment sono stati utilizzati due datasets: AID per costruire il vocabolario (etichette ignorate), UC Merced per addestrare e valutare il classificatore.

PIPELINE ADOTTATA

CREAZIONE DEL VOCABOLARIO VISUALE SU AID

Il vocabolario di parole visuali è stato appreso sul dataset AID, le etichette sono state ignorate. La ragione è concettuale: in BoW il vocabolario rappresenta un insieme di pattern visivi a priori, indipendente dal task di classificazione finale. Mescolare informazioni di classe in questa fase contaminerebbe la rappresentazione.

Come descrittore locale è stato selezionato SIFT (vettori continui a 128 dimensioni). Sebbene inizialmente fosse stato ipotizzato un confronto con ORB, si è preferito optare per SIFT in quanto produce vettori in uno spazio continuo dove la distanza euclidea ha senso geometrico. I descrittori binari come ORB vivono in uno spazio dove la metrica naturale è la distanza di Hamming. Sull'insieme dei descrittori è stato applicato **MiniBatchKMeans** (batch_size=10000). Questa scelta è motivata dalla dimensione del problema: K-Means standard avrebbe comportato costi computazionali e di memoria eccessivi; **MiniBatchKMeans** converge a una soluzione di qualità molto simile in una frazione del tempo e ha permesso di non incorrere in limitazioni hardware.

Il vocabolario è stato costruito per tre dimensioni: $K \in \{50, 100, 500\}$.




Diagramma a blocchi per la Costruzione Vocabolario

CLASSIFICAZIONE

Le immagini UC Merced, rappresentate come vettori BoW L2-normalizzati, vengono classificate con due algoritmi a confronto:

- **SVM a kernel RBF:** il kernel RBF proietta implicitamente i vettori in uno spazio a dimensionalità molto elevata, dove le classi tendono a diventare più facilmente separabili da iperpiani.
- **Random Forest (100 alberi):** alberi decisionali addestrati su sottoinsiemi casuali dei dati. Paradigma completamente diverso dall'SVM: non si basa su distanze o kernel, ma su soglie locali sulle singole componenti dell'istogramma BoW. Il confronto con SVM è informativo perché i due metodi analizzano la rappresentazione in modi opposti

La valutazione segue un protocollo di **3-fold cross-validation** stratificata: i 2.100 campioni vengono suddivisi in 3 fold mantenendo in ciascuno la proporzione delle 21 classi. Le metriche riportate (accuracy e F1-score macro-averaged) sono la media sui 3 fold. Il macro-average tratta tutte le 21 classi con peso uguale, coerentemente con il dataset bilanciato (100 immagini per classe). L'intero processo viene ripetuto per tutte le 6 combinazioni sperimentali: **3 valori di K × 2 classificatori**. La combinazione con F1 macro più alto viene selezionata come modello finale.




Diagramma a blocchi per la pipeline di Classificazione

SCELTE PROGETTUALI

In questa sezione vengono riepilogate sinteticamente le decisioni progettuali principali, con un approfondimento delle scelte meno immediate.

NORMALIZZAZIONE L-2 DEGLI ISTOGRAMMI BOW

Tra le opzioni disponibili, la normalizzazione L2 (norma euclidea unitaria) è stata preferita rispetto alla L1 (somma=1) per due ragioni. La prima, e principale, è la comparabilità: portando ogni istogramma a norma unitaria, immagini con un numero molto diverso di keypoint estratti diventano confrontabili, evitando che un'immagine ricca di descrittori "pesi" di più solo per la quantità. La seconda è che la L2 si integra bene con il kernel RBF dell'SVM, che su vettori unitari vede la distanza euclidea legata direttamente al prodotto scalare (similarità del coseno).

SCELTA DEI CLASSIFICATORI SHALLOW

La combinazione **SVM-RBF + Random Forest** è motivata dalla volontà di massimizzare la **diversità paradigmatica** del confronto. La scelta attuale testa la rappresentazione BoW da angolazioni opposte: l'**SVM-RBF** la valuta come **geometria globale** del vettore (ogni componente contribuisce alla similarità complessiva), il **Random Forest** come presenza/assenza locale di singole visual words (decisioni basate su soglie su componenti specifiche).

IPERPARAMETRI

Tutti gli iperparametri sono stati mantenuti ai **valori di default di scikit-learn**, coerentemente con il suggerimento esplicito della consegna. Concretamente: SVM-RBF con $C=1.0$, $\gamma='scale'$; Random Forest con $n_estimators=100$; MiniBatchKMeans con $batch_size=10000$. Questa scelta è motivata da tre considerazioni: introdurre una grid search avrebbe aggiunto un ulteriore asse sperimentale al confronto, rendendone meno leggibile l'interpretazione; i valori di default di scikit-learn sono pensati per funzionare ragionevolmente bene su una vasta gamma di problemi.

DIMENSIONAMENTO DEL VOCABOLARIO

Per la costruzione del vocabolario sono stati estratti fino a **N=100 descrittori per immagine** di AID, campionati casualmente quando SIFT ne rilevava un numero maggiore. Su un totale di 10.000 immagini AID processate, si è raccolta una matrice di circa **1.000.000 descrittori complessivi**. Il valore di N è il risultato di un compromesso tra due esigenze contrapposte: estrarre abbastanza descrittori da catturare la varietà visiva di ciascuna immagine, e mantenere la matrice complessiva entro limiti gestibili in memoria per il clustering.

BILANCIAMENTO DELLE CLASSI IN CROSS-VALIDATION

Il dataset UC Merced è nativamente bilanciato (100 immagini per ciascuna delle 21 classi). Per preservare questo bilanciamento all'interno di ogni fold della cross-validation, è stata utilizzata la classe *StratifiedKFold* di scikit-learn anziché il più semplice *KFold*. La differenza è importante: *KFold* suddivide casualmente i 2.100 campioni in 3 fold senza garantire che ogni classe sia rappresentata proporzionalmente, mentre *StratifiedKFold* impone esplicitamente che ogni fold mantenga la proporzione delle 21 classi del dataset originale.

RISULTATI OTTENUTI

La seguente tabella illustra i risultati ottenuti dopo l'esecuzione della pipeline:

K	Classificatore	Accuracy (mean ± std)	F1 macro (mean ± std)
50	SVM-RBF	66.6% ± 1.4%	66.2% ± 1.5%
50	Random Forest	62.5% ± 0.2%	61.2% ± 0.3%
100	SVM-RBF	68.2% ± 1.1%	67.8% ± 1.1%
100	Random Forest	61.8% ± 0.5%	60.5% ± 0.6%
500	SVM-RBF	71.6% ± 1.2%	71.3% ± 1.0%
500	Random Forest	60.1% ± 0.5%	58.2% ± 0.7%

MODELLO VINCENTE


Il modello vincente risulta essere **SIFT + K=500 + SVM-RBF** → **accuracy 71.6%, F1 macro 71.3%**.

Metrica	3-fold CV	Held-out 30%
Accuracy	71.6% ± 1.2%	73%
Precision macro	71.9% ± 1.0%	74.0%
Recall macro	71.6% ± 1.1%	73.0%
F1 macro	71.3% ± 1.0%	73%

La tabella ci permette di osservare che le metriche migliorano leggermente passando da CV (71.6%) a held-out (73.0%). È un segnale positivo: il modello non va in overfitting e generalizza bene su dati mai visti; inoltre, la *std* è contenuta (± 1.0 – 1.2%), ciò permette di confermare che il modello è stabile e i risultati non dipendono dal particolare fold.

MATRICE DI CONFUSIONE DEL MODELLO VINCENTE

La matrice è 21×21: ogni riga è la classe reale, ogni colonna la classe predetta. Una diagonale scura significa classificazione corretta. Guardando la diagonale si vede che la maggior parte delle classi viene classificata correttamente.



Le confusioni principali:

1. buildings ↔ denseresidential

- Entrambe mostrano tetti ravvicinati visti dall'alto. BoW raccoglie patch locali di tegole e cemento: gli istogrammi risultano quasi identici. Il modello non vede la struttura globale, solo l'aggregato di texture locali.

2. `mediumresidential` ↔ `sparseresidential`
 - a. La differenza tra queste classi è puramente nella densità degli edifici. Le visual words estratte sono le stesse (stessi materiali, stesse forme) solo in quantità diverse. Un istogramma BoW non codifica questa informazione.
3. `storagetanks` ↔ `freeway`
 - a. Entrambe hanno strutture geometriche regolari e ripetitive: i serbatoi cilindrici e le corsie autostradali generano visual words simili legate a bordi netti e pattern periodici.

Queste confusioni non sono casuali: sono tutte spiegabili e coerenti con il limite fondamentale del BoW. Senza informazione spaziale, classi visivamente diverse a livello globale ma simili a livello locale risultano ambigue per il modello.

PROBLEMI RISCONTRATI

Problema Riscontrato: Alcune immagini aeree non presentano un numero sufficiente di gradienti locali. In questi casi, l'algoritmo di estrazione (SIFT) non rileva alcun punto di interesse e restituisce descrittori nulli (None). Senza gestione esplicita, questo scenario causa due conseguenze: un *np.vstack* su lista vuota lancerebbe un errore se nessuna immagine producesse descrittori; durante la generazione degli istogrammi BoW, l'immagine verrebbe semplicemente omessa, causando un disallineamento tra le righe della matrice X e il vettore delle etichette y.

Soluzione Adottata (Strategia Difensiva a Due Livelli):

1. **Fase estrazione (01):** le immagini senza keypoint vengono saltate con *continue* e conteggiate in un avviso a log, non entrano nel vocabolario.
2. **Fase BoW (03):** se un'immagine non produce keypoint, le viene assegnato un istogramma di zeri di dimensione K. L'immagine rimane nella matrice X (nessun disallineamento con y) e il classificatore la tratta come un campione con distribuzione uniforme delle visual words.

Questa soluzione garantisce la totale stabilità e robustezza della pipeline contro i difetti intrinseci delle immagini telerilevate. Previene eccezioni a runtime e consente ai classificatori shallow (SVM e Random Forest) di gestire l'anomalia, preservando l'automazione del flusso e l'integrità del protocollo di 3-Fold Cross-Validation senza richiedere la rimozione manuale dei campioni.

POSSIBILI MIGLIORAMENTI

NESSUNA INFORMAZIONE SPAZIALE

Per ovviare alla limitazione del paradigma BoW di non fornire alcuna informazione spaziale (ciascuna immagine è rappresentata come istogramma di visual words) si potrebbe optare nel dividere l'immagine in griglie e calcolare un istogramma BoW per ciascuna, così facendo due immagini con le stesse visual words ma in posizioni differenti produrranno vettori diversi.

HARD ASSIGNMENT

Ogni descrittore viene assegnato a una sola visual words, quella del centroide più vicino. Qualora un descrittore cadesse a metà tra due centroidi viene assegnato arbitrariamente a uno dei due: l'informazione sulla sua ambiguità viene persa. Per poter risolvere questo problema si potrebbe stabilire che ogni descrittore può contribuire a più visual words, con peso proporzionale alla distanza.

BIBLIOGRAFIA

Durante lo sviluppo dell'assignment ho utilizzato come strumento di supporto alla progettazione il modello di intelligenza artificiale **Gemini 3.0/3.1** e Claude (Anthropic). L'impiego dell'AI mi ha consentito di velocizzare il processo di debugging e di ottimizzazione del progetto.

Modalità di utilizzo:

- Discussione delle scelte progettuali e architetturali della pipeline
- Revisione e debugging degli script Python
- Comprensione teorica degli algoritmi (BoW, SIFT, K-Means, SVM-RBF)

TESTI E RISORSE UTILIZZATE

Materiale Didattico del Corso: Slide e appunti forniti durante le lezioni.

Sito Web: <https://www.pinecone.io/learn/series/image-search/bag-of-visual-words/>

(Utilizzato per avere una visione d'insieme dell'argomento Bag Of Visual Words)

Librerie Software:

- *OpenCV (Open-Source Computer Vision Library)*
- *Pandas*
- *Scikit-learn 1.4*

